

¿Qué es Big Data?

Unidad 1

Módulo – Big Data
¿Qué es BigData?

¿Qué es Big Data?	3
Las 5V del Big Data.....	3
Ejemplos reales de Big Data.....	4
Diferencia entre BI (Business Intelligence) y Big Data.....	6
Arquitectura general de un sistema Big Data	7
1. <u>Captura de datos</u>	8
2. <u>Almacenamiento distribuido</u>	9
3. <u>Procesamiento masivo</u>	10
4. <u>Análisis y visualización</u>	11
BLOQUE 1: Actividad sugerida	13
BLOQUE 2: Ejercicios	13

Big Data se refiere al conjunto de tecnologías, herramientas y técnicas utilizadas para recopilar, almacenar, procesar y analizar grandes volúmenes de datos que debido a su tamaño, velocidad de generación y variedad no pueden ser tratados de manera eficiente con herramientas tradicionales.

¿QUÉ ES EL BIG DATA?

VOLUMEN

VELOCIDAD

VARIEDAD

VERACIDAD

VALOR

BIG DATA

85%

1. **Volumen:** Cantidades masivas de datos generados cada segundo por dispositivos, redes sociales, sensores, transacciones, etc.
2. **Velocidad:** Rapidez con la que se generan y procesan los datos (por ejemplo, datos en tiempo real).
3. **Variedad:** Diversidad de formatos (estructurados, no estructurados, semiestructurados), como textos, imágenes, videos, sensores, etc.
4. **Veracidad:** Calidad y fiabilidad de los datos, que no pueden contener errores o inconsistencias.
5. **Valor:** Utilidad que se puede obtener de los datos al analizarlos correctamente para tomar decisiones informadas.

Ejemplos reales de Big Data

- Análisis de sentimientos en redes sociales (Twitter, Instagram).
- Recomendaciones personalizadas de productos en Amazon o Netflix.
- Detección de fraudes bancarios.
- Sensores IoT en fábricas o coches conectados. **IoT** (Internet of Things) significa Internet de las Cosas. Es el concepto de conectar objetos físicos a Internet para que recojan, envíen o intercambien datos. **Sensores IoT** son dispositivos que miden o detectan algo en el mundo físico y envían esos datos de forma digital.
- Monitoreo de salud (Datos de salud y genómica) en medicina personalizada mediante dispositivos portátiles.

Por ejemplo, **Netflix podría extraer la cantidad masiva de datos que tiene de sus usuarios**, para tratarlos y descubrir que el 80% de sus usuarios han visto 'Stranger Things' en pocos días. Con esto, pueden llegar a la conclusión de que este tipo de series pueden ser muy rentables para su negocio.

Otro ejemplo, ¿Sabías que la **Coca-Cola** tiene diferente sabor dependiendo del país en el que la tomes? ¿Y que hay sabores que solamente están en ciertos países? Esto sucede porque Coca-Cola ha observado en sus datos que existen ciertos sabores que encajan mejor con los hábitos de consumo a nivel masivo de esos países. A algunos países les gusta más el dulce, en otros más las burbujas, en otros sabores de frutas... Y, una vez representan estos datos, **toman decisiones para abarcar una mayor cuota de mercado**.


Y otro ejemplo, **Spotify** utiliza Big Data para **recomendar música y crear listas de reproducción personalizadas** para los usuarios. De hecho, tienen una funcionalidad muy curiosa con la que amplían tu playlist con canciones que podrían gustarte con tan solo hacer un clic en un botón. Todo esto es posible porque almacenan mucha información sobre nuestros hábitos de escucha, y sus **algoritmos** la tratan para ofrecernos una experiencia lo más personalizada y satisfactoria posible.



Conclusión, si eres el CEO de una empresa (son las siglas de Chief Executive Officer, que significa director ejecutivo) o trabajas para una de ellas, seguro que te resultará de interés saber cómo podéis aplicar el **Big Data** para una toma de decisiones más racional. Es, por ejemplo, una de las máximas sobre las que se basa el **Growth Hacking**: tomar decisiones estratégicas en base a los datos que tenemos. Y es que el Big Data puede ser utilizado para una amplia variedad de propósitos, desde la mejora de la eficiencia empresarial hasta la toma de decisiones de si lanzar o no un determinado producto o servicio.




Diferencia entre BI (Business Intelligence) y Big Data



Resumiendo:

- **BI** trabaja con datos estructurados y análisis históricos.
- **Big Data** permite trabajar también con datos no estructurados y en tiempo real.
- **BI** usa herramientas como Excel, Power BI, etc., mientras **Big Data** se apoya en tecnologías como **Hadoop**, **Spark**, Kafka.

Arquitectura general de un sistema Big Data



Una arquitectura típica incluye:

1. **Captura de datos** (APIs, sensores, logs...)
2. **Almacenamiento distribuido** (HDFS (Hadoop Distributed File System), NoSQL, SAP Sybase, SAP Hana...)
3. **Procesamiento masivo** (Spark, Flink...)
4. **Análisis y visualización** (Python, dashboards)

1. Captura de datos


Objetivo: Ingerir datos desde múltiples fuentes, en tiempo real o por lotes.

Fuentes comunes:

- **APIs** (REST, SOAP): datos estructurados desde servicios web.
- **Sensores / IoT**: datos en tiempo real (temperatura, velocidad, etc.).
- **Logs** (aplicaciones, servidores, redes): datos semiestructurados.
- **Bases de datos tradicionales**: extracción periódica (ETL/ELT).
- **Redes sociales, emails, clics web**.

Tecnologías frecuentes:

- **MQTT**: Recibe datos de dispositivos IoT → se manda a un broker MQTT.
- **Flume**: Captura logs de servidores web → los envía a NiFi o HDFS directamente.
- **Sqoop**: Transfiere datos entre bases de datos relacionales y Hadoop.
- **NiFi**: Orquesta y enruta datos → integra múltiples fuentes (MQTT, Flume, Sqoop) y los dirige a destinos como Kafka.
- **Kafka**: Almacena y distribuye los eventos en tiempo real → los consumidores (p.ej. Spark Streaming) procesan y escriben en el Data Lake/DWH.



2. Almacenamiento distribuido


Objetivo: Almacenar grandes volúmenes de datos de forma escalable y tolerante a fallos.

Características clave:

- Soporte para datos estructurados, semiestructurados y no estructurados.
- Escalabilidad horizontal (añadir más nodos).

Tecnologías comunes:

- **Data Lakes:** guardan datos en bruto, cualquier formato.
- **Data Warehouses:** datos estructurados para análisis SQL.
- **NoSQL:** bases de datos flexibles, optimizadas para distintos modelos.
- **HDFS:** (Hadoop Distributed File System) sistema de archivos distribuido, pilar del big data clásico.



3. Procesamiento masivo


Objetivo: Transformar y analizar grandes cantidades de datos en tiempo real o por lotes.

Tipos de procesamiento:

- **Batch:** procesamiento por lotes (alta latencia, alta complejidad).
- **Streaming:** procesamiento en tiempo real o casi real.

Tecnologías clave:

- Batch -> Procesamiento por lotes (**Hadoop MapReduce, Apache Spark**).
- Streaming -> Procesamiento de datos en tiempo real (**Apache Flink, Apache Storm, Apache Samza, Apache Spark Structured Streaming**).
- Unificadas -> Frameworks que soportan ambos modos (**Apache Beam, Apache Spark, Apache Flink**).



4. Análisis y visualización


Objetivo: Generar insights, modelos predictivos y reportes visuales a partir de los datos.

Herramientas y tecnologías:

- **Lenguajes de análisis:** Para análisis y modelado.
- **BI & Dashboards:** Crear dashboards visuales.
- **Notebooks interactivos:** Experimentos y prototipos interactivos.
- **ML/IA:** Frameworks para entrenamiento y despliegue de modelos.



Diagrama resumen (flujo general) arquitectura:



BLOQUE 1: Actividad sugerida

Busca en Internet un caso real de uso de Big Data y haz un breve resumen (máx. 150 palabras). Ejemplos: Netflix, Zara, Amazon, Telefónica

BLOQUE 2: Ejercicios

1. Define con tus palabras qué es Big Data.
2. Explica qué significan las 5V del Big Data y pon un ejemplo de cada una.
3. Compara BI y Big Data: ¿cuáles son sus principales diferencias?
4. Dibuja una arquitectura típica de sistema Big Data con sus cuatro bloques.