

TEST

UNIDAD 2
Ecosistema
Hadoop y Spark

1. **¿Cuál de los siguientes no es un componente del ecosistema Hadoop?**
 - a) HDFS
 - b) MapReduce
 - c) YARN
 - d) MySQL**
2. **HDFS se utiliza principalmente para:**
 - a) Procesamiento de datos en tiempo real
 - b) Almacenamiento distribuido de grandes volúmenes de datos**
 - c) Administración de bases de datos SQL
 - d) Visualización de datos
3. **MapReduce se basa en el concepto de:**
 - a) Dividir y conquistar (split and join)
 - b) Mapear y reducir tareas en paralelo**
 - c) Guardar y recuperar datos
 - d) Consultas SQL
4. **¿Cuál de los siguientes lenguajes se puede usar para escribir jobs en Spark?**
 - a) Python
 - b) Java
 - c) Scala
 - d) Todos los anteriores**
5. **¿Qué componente de Hadoop facilita es el encargado de controlar y coordinar el uso de CPU, memoria y almacenamiento en todo el clúster?**
 - a) MapReduce
 - b) HDFS
 - c) HBase
 - d) YARN**
6. **¿Cuál es la función de YARN en Hadoop?**
 - a) Almacenar datos distribuidos
 - b) Coordinar recursos y tareas de procesamiento**
 - c) Ejecutar consultas SQL
 - d) Generar gráficos de datos
7. **Spark se diferencia de Hadoop MapReduce porque:**
 - a) Solo funciona con datos en memoria
 - b) Permite procesamiento en memoria y más rápido**
 - c) No soporta Java
 - d) No se puede integrar con HDFS
8. **HDFS es un sistema:**
 - a) De ficheros distribuidos**
 - b) De base de datos NoSQL distribuida
 - c) De procesamiento batch
 - d) De orquestación de tareas

9. **¿Cual es el objetivo de MapReduce?**
a) Almacenar grandes volúmenes de datos de manera distribuida.
b) Procesar grandes cantidades de datos dividiéndolos en tareas paralelas y luego combinando los resultados.
c) Ejecutar consultas SQL sobre datos estructurados.
d) Administrar recursos del cluster.
10. **Spark Streaming se utiliza para:**
a) Procesar datos históricos
b) Procesar datos en tiempo real
c) Guardar datos en HDFS
d) Consultas SQL
11. **PySpark es la interfaz de Spark para:**
a) Java
b) Python
c) Scala
d) RDD
12. **¿Qué objeto principal se utiliza en PySpark para trabajar con datos distribuidos?**
a) DataFrame
b) RDD
c) Dataset
d) SQLContext
13. **Para leer un archivo CSV en PySpark se utiliza:**
a) spark.read.csv("archivo.csv")
b) pd.read_csv("archivo.csv")
c) RDD.textFile("archivo.csv")
d) open("archivo.csv")
14. **Para ejecutar operaciones SQL sobre un DataFrame en PySpark, primero necesitamos:**
a) SparkContext
b) SQLContext o SparkSession
c) HDFS
d) MapReduce
15. **¿Qué método de DataFrame se usa para mostrar las filas en PySpark?**
a) head()
b) show()
c) display()
d) first()
16. **PySpark permite procesamiento en:**
a) Batch
b) Streaming
c) Batch y Streaming
d) Solo almacenamiento

17. ¿Qué librerías integradas ofrece Spark para distintos tipos de procesamiento y análisis de datos?
- a) **Spark SQL, MLlib, GraphX, Spark Streaming**
 - b) Pandas, NumPy, Matplotlib, Seaborn
 - c) Hadoop, Spark, Pig, HBase
 - d) TensorFlow, PyTorch, Keras, Scikit-learn
18. ¿Cuál es el resultado de aplicar `filter(df["edad"] > 18)` a un DataFrame df?
- a) Se eliminan todas las filas donde la edad sea mayor que 18
 - b) **Se seleccionan solo las filas donde la edad sea mayor que 18**
 - c) Se agrega una nueva columna llamada edad
 - d) Se calcula la media de la columna edad
19. Para contar el número de filas en cada grupo de un DataFrame después de `groupBy("columna")` se utiliza:
- a) `.sum()`
 - b) **`.count()`**
 - c) `.mean()`
 - d) `.collect()`
20. Después de usar `groupBy()`, para obtener la suma de una columna se utiliza:
- a) **`.sum()`**
 - b) `.count()`
 - c) `.filter()`
 - d) `.map()`