

Instalación del entorno de trabajo PySpark en IDEs como Visual Code y NetBeans

1. Instalar Python

- 1.1. Ve a python.org/downloads.
- 1.2. Descarga la versión 3.10 o superior.
- 1.3. Durante la instalación, marca la opción “Add Python to PATH”.
- 1.4. Verifica la instalación en la terminal/Command Prompt:

```
python --version
```

Deberías ver algo como:

```
Python 3.11.4
```

2. Instalar PySpark

- 2.1. Abre la terminal (o CMD/PowerShell).
- 2.2. Ejecuta:

```
pip install pyspark
```

Esto instalará Apache Spark para usarlo desde Python.

3. Configurar en Visual Studio Code

- 3.1. Abre VS Code y vete a Extensiones → busca Python → instala la extensión oficial.
- 3.2. Crea un archivo ejemplo.py con tu código PySpark:

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.appName("Ejemplo").getOrCreate()

data = [
    {"nombre": "Ana", "edad": 25, "ciudad": "Madrid"},
    {"nombre": "Luis", "edad": 35, "ciudad": "Barcelona"},
    {"nombre": "Pedro", "edad": 40, "ciudad": "Madrid"},
    {"nombre": "Laura", "edad": 28, "ciudad": "Valencia"}
]

df = spark.createDataFrame(data)
df.filter(df["edad"] > 30).groupBy("ciudad").count().show()
```

- 3.3. Ejecuta desde la terminal:

```
python ejemplo.py
```

Si todo está bien, verás la salida del DataFrame filtrado.

4. Configurar en NetBeans

NetBeans no es nativo para Python, pero puedes usarlo con el plugin NBPython o usando NetBeans como editor y ejecutando Python desde terminal.

- 4.1. Instala el plugin NBPython (opcional, facilita trabajar con proyectos Python).
- 4.2. Crea un proyecto Python en NetBeans:
- 4.3. Proyecto → Python → Python Project.
- 4.4. Copia tu archivo ejemplo.py con el código PySpark.

```
from pyspark.sql import SparkSession

spark = SparkSession.builder.appName("Ejemplo").getOrCreate()

data = [
    {"nombre": "Ana", "edad": 25, "ciudad": "Madrid"},
    {"nombre": "Luis", "edad": 35, "ciudad": "Barcelona"},
    {"nombre": "Pedro", "edad": 40, "ciudad": "Madrid"},
    {"nombre": "Laura", "edad": 28, "ciudad": "Valencia"}
]

df = spark.createDataFrame(data)
df.filter(df["edad"] > 30).groupBy("ciudad").count().show()
```

- 4.5. Ejecuta desde NetBeans o desde la terminal del proyecto:

```
python ejemplo.py
```

Nota: PySpark se ejecuta en la JVM, pero usando pip install pyspark no necesitas instalar Spark por separado; solo necesitas Python y Java (Java 8 o superior).