

PySpark Ejercicios - Nivel Básico y Avanzado

A continuación se muestran una serie de ejercicios básicos y avanzados. Deberás crearte el archivo **personas.csv** y **ventas.csv** de ejemplo para luego hacer los ejercicios.

Nombre del archivo: **personas.csv**

```
nombre,edad,ciudad,salario,monto
Ana,25,Madrid,30000,200
Luis,40,Barcelona,50000,1500
Marta,35,Madrid,45000,1200
Carlos,28,Sevilla,38000,700
Lucía,50,Barcelona,60000,2500
Diego,22,Sevilla,28000,300
Elena,31,Madrid,42000,900
```

Nombre del archivo: **ventas.csv**

```
id_venta,nombre,producto,monto
1,Ana,Portátil,1200
2,Luis,Móvil,800
3,Marta,Tablet,600
4,Ana,Monitor,300
5,Luis,Portátil,1300
6,Carlos,Móvil,700
7,Ana,Teclado,100
8,Lucía,Portátil,2000
9,Elena,Tablet,500
10,Lucía,Móvil,1500
11,Luis,Monitor,400
12,Ana,Móvil,900
13,Marta,Portátil,1400
14,Diego,Tablet,450
15,Elena,Móvil,1000
```

NOTA: Recuerda importar todas las librerías necesarias

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col,sum,.....
```

NOTA: La teoría está en la unidad 2 página 10.

Dado el archivo **personas.csv** de ejemplo, realiza los siguientes ejercicios:

Ejercicios Básicos

- Ejercicio 1: Filtrar edades

Muestra solo las personas que tienen más de 30 años.

- Ejercicio 2: Contar por ciudad

Cuenta cuántas personas hay en cada ciudad.

- Ejercicio 3: Seleccionar columnas

Muestra solo el nombre y la edad de todas las personas.

- Ejercicio 4: Ordenar por edad

Muestra todos los registros ordenados de mayor a menor según la edad.

- Ejercicio 5: Crear nueva columna

Crea una columna nueva que sea la edad más 5 años.

- Ejercicio 6: Suma de un valor

Suma todos los valores de la columna monto.

- Ejercicio 7: Promedio de edades

Calcula el promedio (avg) de la columna edad.

- Ejercicio 8: Filtrar por ciudad

Muestra solo las personas que viven en la ciudad "Madrid".

- Ejercicio 9: Contar filas

Cuenta cuántos registros hay en el DataFrame.

- Ejercicio 10: Mínimo y máximo

Muestra la edad mínima y máxima de las personas.

Ejercicios Avanzados

- **Ejercicio 11: Join de DataFrames**

Une los datos de personas con sus ventas y muestra el nombre de la persona y el monto de cada venta. Nota: Hacer join entre personas y ventas por la columna nombre.

- **Ejercicio 12: Agregación de ventas**

Para cada producto, calcula la suma total, el promedio y la venta más alta.

- **Ejercicio 13: Clientes frecuentes**

Cuenta cuántas compras hizo cada cliente y muestra solo los que compraron más de 3 veces.

- **Ejercicio 14: Clientes con compras grandes**

Calcula el total comprado por cada cliente y muestra solo los que gastaron más de 5000.